7115056046_hw2

實驗成果與線上展示:

本研究使用 Python 與 Scikit-learn 建立多元線性回歸模型，並比較 Lasso、Forward SFS、RFE、ElasticNet 及 Exhaustive Search 等特徵選取方法。
模型於測試集上取得 $R^2 = 0.5824$、RMSE = 138.99、MAE = 100.92，並建立名義 95% 的預測區間，測試集實際覆蓋率為 94.40%。
為了完整呈現實驗成果，本研究將模型評估、特徵選取、預測區間及互動式情境模擬器整合至 GitHub Pages 網頁，並公開 Python 原始程式碼供檢視。
GitHub Repository：
https://github.com/Chen-Fanny/HW2-Multiple-Linear-regression
GitHub Pages：
https://chen-fanny.github.io/HW2-Multiple-Linear-regression/

● CRISP-DM 分析流程

研究題目：基於多元線性回歸與特徵選取之共享單車需求預測

1. Business Understanding（商業理解）

隨著共享單車逐漸普及，不同時間及天氣條件下的租借需求也存在明顯差異。例如，上下班尖峰時段通常具有較高的租借需求，而下雨或極端天氣可能降低民眾使用共享單車的意願。
因此，本研究希望透過機器學習中的多元線性回歸（Multiple Linear Regression），分析時間、氣溫、濕度及天氣等因素與共享單車租借數量之間的關係，進而預測每小時的租借需求。
研究目標除了提升預測能力，也希望透過特徵選取找出重要的影響因素，協助共享單車業者進行車輛調度與資源分配。

2. Data Understanding（資料理解）

本研究採用 UCI Bike Sharing Dataset，並使用其中的 hour.csv 作為分析資料。
資料共包含 17,379 筆每小時共享單車租借紀錄，紀錄時間涵蓋 2011 年至 2012 年。
主要欄位如下：

特徵	說明
hr	小時（0–23）
season	季節
yr	年份
workingday	是否為工作日
weathersit	天氣狀況
temp	標準化溫度

atemp	標準化體感溫度
hum	標準化濕度
windspeed	標準化風速
cnt	每小時總租借量（Target）

本研究透過描述性統計、相關係數熱圖，以及不同時間的租借需求分布圖，了解各變數與租借數量之間的關係。

其中，氣溫與體感溫度具有高度相關性，因此後續也將進行多重共線性分析。

3. Data Preparation（資料準備）

為提高模型預測的可靠性，本研究首先進行資料清理，檢查缺失值與欄位型態，並移除不適合作為預測輸入的欄位。

由於 casual（非註冊用戶）與 registered（註冊用戶）的租借數量加總等於 cnt，若將兩者作為輸入特徵，會造成 Data Leakage（資料洩漏），因此予以排除。

接著透過 Feature Engineering（特徵工程），建立尖峰時段指示變數 is_rush_hour、時間週期特徵 hr_sin、hr_cos，以及溫度與濕度交互特徵 temp_hum 等，最終建立包含 18 個輸入特徵的模型。

為避免未來資料影響過去的預測，本研究依時間順序切分資料：

資料集	比例	用途
Training	60%	訓練模型
Validation	15%	特徵選取與模型比較
Calibration	10%	計算預測區間
Testing	15%	最終模型評估

此方法能更合理地模擬使用過去資料預測未來需求的情境。

4. Modeling（模型建立）

本研究使用 Python 與 Scikit-learn 建立多元線性回歸模型，以時間、天氣及其他相關特徵預測每小時共享單車租借數量。

多元線性回歸公式如下：

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

其中：

- $\hat{y}$：預測的共享單車租借數量。
- β_0：截距。
- β_i：各特徵的迴歸係數。
- x_i：輸入特徵。

為了探討不同特徵組合是否能改善預測結果，本研究比較五種特徵選取及正則

化方法：

方法	主要目的
Lasso	將部分特徵係數壓縮為零
Forward SFS	逐步加入有用特徵
RFE	反覆移除較不重要的特徵
ElasticNet	結合 L1 與 L2 正則化
Exhaustive Search	比較指定範圍內的特徵組合

透過比較各方法的 Validation RMSE，分析特徵選取對模型預測能力的影響。
其中 Lasso 可減少不必要的特徵，而 Forward SFS 能找出較具預測價值的特徵組合。

5. Evaluation（模型評估）

本研究使用四種常見回歸評估指標，包含 MAE、MSE、RMSE 以及 R^2，評估模型的預測準確程度。
其中，RMSE 與 MAE 越低，代表預測誤差越小；R^2 越接近 1，表示模型能解釋的目標變異比例越高。
根據目前的 OLS Baseline 實驗結果：

評估指標	Training	Testing
R^2	0.6991	0.5824
RMSE	73.84	138.99
MAE	55.62	100.92

由結果可知，模型在測試集上的 R^2 為 0.5824，代表模型能解釋約 58.24% 的測試資料租借量變異。
然而，測試集表現低於訓練集，顯示模型對未來資料的泛化能力仍有改善空間。
此外，本研究利用 **Split Conformal Prediction（分割共形預測）**建立名義 95% 預測區間，並在測試集上取得 94.40% 的實際覆蓋率。
此結果能提供單一預測值以外的不確定性參考，但由於共享單車資料具有時間相依性，預測區間的理論覆蓋保證仍須考慮資料交換性等假設。
最後，本研究透過預測值與實際值比較圖、殘差分析圖，以及預測區間圖，進一步觀察模型的預測表現與限制。

6. Deployment（部署與應用）

為了讓模型成果更容易展示與理解，本研究將分析結果整合為互動式網頁，並透過 GitHub Pages 提供線上展示。

網頁包含模型評估指標、迴歸係數分析、特徵選取比較，以及預測區間視覺化等功能。

此外，網頁亦設計互動式情境模擬器，讓使用者透過調整時間、氣溫、濕度及天氣等參數，觀察共享單車需求預測值的變化。

本研究完成了從資料分析、模型建立、結果評估至成果展示的完整流程，未來可進一步比較 Random Forest、XGBoost 或 LightGBM 等非線性模型，以改善線性回歸在複雜需求變化下的預測限制。

- **GPT 對話過程（而外給 pdf 檔案）**

- **NotebookLM 研究摘要:**

1. 共享單車需求預測的研究背景及重要性

共享單車系統（Bike-Sharing System, BSS）作為物聯網（IoT）與智慧城市微交通（Micro-mobility）的核心基礎設施，具備減少碳排放、緩解市區交通壅塞與解決「最後一哩路」接駁等多重效益。

在系統營運層面，最大的挑戰在於**車輛空間與時間分佈的不平衡（Asymmetric Distribution）**。例如早晨通勤尖峰時段，住宅區租借站常因車輛被借空而「無車可借」，商業區或轉運站則因車輛大量湧入而「無柱可還」；傍晚尖峰則完全反轉。

精準的每小時需求預測（Hourly Demand Prediction）對於以下物聯網應用至關重要：

- **動態車輛調度（Rebalancing Operations）**：提前規劃調度卡車路徑與搬運量，大幅降低營運燃油成本與空轉時間。
- **車柱與電力資源調控**：智慧車柱可根據預估流量調整休眠模式與即時通訊頻率，達成物聯網節點能源最佳化。
- **提升服務水準（Level of Service, LoS）**：維持各站適足率，避免使用者因連續缺車或無位還車而降低搭乘意願。

---

2. 多元線性回歸（MLR）應用、特徵選取機制與優缺點

(1) 模型應用形式

多元線性回歸將每小時租借總量 \(y_i\)（cnt）表示為輸入環境與時間特徵向量 \(X_i\) 的線性組合： \[\hat{y}*i = *beta_0 + *sum{j=1}^p \beta_j X_{ij}\]

在時間序列特徵處理上，常將時間戳記拆解為週期性或分類特徵（月份、星期、小時等），並可針對目標變數採取對數轉換 \(\log(y+1)\) 以保證非負性預測。

(2) 特徵選取方法機制（Feature Selection）

在 Scikit-learn 與相關機器學習套件中，針對線性模型之特徵選取機制可分為三類：

- **Lasso（L1 Regularization）**：在目標函式加入 L1 正則化懲罰項 \(\alpha \sum_{j=1}^p |\beta_j|\)。L1 幾何形狀具備稜角特性，能將不顯著特徵的權重直接壓縮為零，達到內建特徵選取（Embedded Selection）效果。
- **ElasticNet（L1 + L2 Regularization）**：結合 Lasso（L1）與 Ridge（L2）懲罰項。當特徵之間存在高共線性時（如氣溫 temp 與體感溫度 atemp），Lasso 常會隨機挑選其中一個而忽略另一個；ElasticNet 能產生「群組效應（Grouping Effect）」，同時保留具相關性的一組特徵。

- **Forward Sequential Feature Selector（Forward SFS）**：屬於包裹法（Wrapper Method）。從空特徵集合開始，貪婪地（Greedily）逐一加入能使交叉驗證評估分數（如 R^2 或負 MSE）提升最大的特徵，直到達到設定數量。
- **Recursive Feature Elimination（RFE）**：同樣為包裹法，初始使用全特徵訓練模型，根據回歸係數絕對值 $|\beta_j|$ 或特徵權重由小到大遞迴剔除最不重要的特徵，直到剩下目標特徵數。
- **Exhaustive Feature Search**：窮舉評估所有 $2^p - 1$ 種特徵組合，保證在給定準則下找出全域最佳特徵子集，但計算複雜度隨特徵數量呈指數成長 $O(2^p)$。

(3) 優點與限制

- 優點：
    1. **高度可解釋性（Interpretability）**：回歸係數 β_j 直接代表其他特徵固定下，該特徵變動一單位對租借量的邊際效應（Marginal Effect）。
    2. **運算開銷極低**：具備解析解（Normal Equation）或快速凸最佳化收斂，適合理論驗證與資源受限之邊緣運算裝置。
- 限制：
    1. **線性假設約束**：真實環境中租借需求對溫度、濕度常呈現非線性關係（例如高溫超過閾值時租借量反轉下降），線性回歸無法直接捕捉此非單調趨勢。
    2. **特徵交互作用捕捉不易**：無法自動學習特徵交乘（如「小時 $\times$ 工作日」的尖峰分流），需人工手動建立特徵工程。
    3. **負值預測風險**：若直接預測原始租借量，於深夜或極端氣候條件下易預測出物理上不合理的負需求數值（$\hat{y} < 0$）。

---

3. 與其他主流機器學習模型之比較

根據文獻（如 2024 年 MDPI *Sustainability* 發表的共享單車預測研究 Torres et al., 2024）與實務應用，主流非線性集成模型包括：

演算法	架構類型	處理非線性與交互作用	超參數調校複雜度	特色與限制
Random Forest (RF)	Bagging（隨機森林）	優異（多顆去相關決策樹平均）	中等（主要調 n_estimators, max_depth）	**抗過雜訊能力強**，不易過擬合；Torres et al. (2024) 指出 RF 精度與 Boosting 相當，但**調校最穩**

				定且最容易部署。
Gradient Boosting (GBDT)	Boosting（殘差迭代）	優異（依負梯度方向逐棵優化）	較高（需平衡學習率與樹深）	能逐步逼近複雜函數，但循序訓練速度較慢，易受異常值干擾。
XGBoost	Regularized Boosting	極佳（二階泰勒展開式與直方圖切分）	高（學習率、正則項 \(\alpha/\lambda\)、子抽樣）	內建樹結構複雜度正則化懲罰，支援稀疏矩陣與精準切分點計算。
LightGBM	Leaf-wise GBDT	極佳（基於 GOSS 與 EFB 演算法）	高（num_leaves, max_depth）	採**葉節點優先（Leaf-wise）**生長，訓練速度最快、記憶體消耗最低，非常適合百萬級物聯網時序數據。

---

4. 天氣、環境與時間特徵對租借需求的影響分析

從實際資料集 day.csv 的統計分佈與特徵關聯性可觀察出明確規律：

1. **溫度與體感溫度（temp, atemp）**：
   - 溫度與總租借量呈**高度正相關**（Pearson 相關係數約 \(+0.627\) 至 \(+0.631\)）。
   - 在低溫至舒適氣溫區間內，租借量隨溫度上升顯著增長；但當夏季極端炎熱（標準化溫度 \(> 0.8\)）時，白天的休閒騎乘需求會受到熱島效應壓抑。
2. **濕度（hum）與風速（windspeed）**：
   - 濕度與需求呈負相關（約 \(-0.101\)），風速亦呈負相關（約 \(-0.235\)）。
   - 高濕度往往伴隨降雨或悶熱不適感，強風則顯著增加踩踏阻力，降低騎乘意願。
3. **天氣狀況（weathersit）**：
   - 晴朗或多雲（Weather Sit 1）平均每日租借量達 **4,877 輛**。
   - 薄霧與陰天（Weather Sit 2）平均降至 **4,036 輛**。
   - 小雨雪或雷雨（Weather Sit 3）平均僅剩 **1,803 輛**（驟降超過 60%）。

4. **季節（season）**：
    - 租借最高峰落在**秋季（Season 3，平均 5,644 輛）與夏季（Season 2，平均 4,992 輛）**。
    - 冬季與春初（Season 1）因氣候寒冷，平均僅約 **2,604 輛**。
5. **工作日（workingday）與時間（hr）的交互行為**：
    - **工作日（Workingday = 1）**：總平均約 4,585 輛，以**註冊通勤會員（registered）為絕對主力（平均 3,978 輛）**，散客（casual）僅 607 輛。每小時呈現顯著的「雙峰分佈」（08:00 與 17:00–18:00 上下班尖峰）。
    - **非工作日（Workingday = 0，週末與假日）**：總平均約 4,330 輛，但**散客租借量倍增至 1,371 輛**。每小時呈現午後單一寬平峰（12:00–16:00 休閒出遊高峰）。

---

5. 資料集切分機制與評估指標分析

進行模型評估時，切分方式與指標選擇對客觀性至關重要：

(1) 資料集切分機制之陷阱

- **Kaggle Competition 切分機制**： Kaggle 競賽將每個月的 **1 日至 19 日設為訓練集（Train Set）**，**20 日至月底設為測試集（Test Set）**，且測試集目標標籤不公開。
- **UCI 原始基準資料集切分**： UCI 資料集包含完整兩年（2011–2012）的連續時間序列（共 17,389 筆小時資料）。
- **注意事項**：若在 UCI 資料集上直接使用 train_test_split(shuffle=True) 進行隨機抽樣切分，會造成**時序資訊外洩（Data Leakage）**（同天相鄰小時的氣候與流量會同時出現在訓練與測試集），導致測得之指標虛高。正確作法應使用**時間序列前向切分（Time-series Split，如以 2011 年訓練、2012 年驗證）**。因此，不可將 UCI 隨機切分的數據直接與 Kaggle 榜單成果混為一談。

(2) 評估指標特性差異

- **RMSLE（Root Mean Squared Logarithmic Error）**： $$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n \left(\log(p_i + 1) - \log(a_i + 1)\right)^2}$$
    - **優勢**：Kaggle 官方指定指標。由於取對數差，它衡量的是**相對誤差（Percentage/Ratio Error）而非絕對差值；即便尖峰時段租借量大，也不會單方面主導整體懲罰；對預測值低估（Underestimate）的懲罰高於高估（Overestimate）**，符合租借站防範空站的營運偏好。
- **RMSE（Root Mean Squared Error）**： 對大誤差施加二次方重罰，對尖峰流量預測失準極度敏感。
- **MAE（Mean Absolute Error）**： 計算預測與真實單車數量的絕對誤差平

均，對離群值較具魯棒性，物理意義直觀（平均誤差幾台車）。

- **\(R^2\)（決定係數）**： 說明模型對總變異的解釋比例。無法跨越不同目標轉換尺度（如直接預測 \(y\) vs. 預測 \(\log(y+1)\)）進行絕對分數的直接比較。

---

6. 多元線性回歸與其他主流方法的差異總結

比較維度	多元線性回歸（**MLR + 特徵選取**）	**樹狀集成模型（RF / XGBoost / LightGBM）**
邊界型態	超平面（Hyperplane），強烈受限於線性單調性	階梯狀非線性曲面，自動劃分條件空間
時段交互特徵	必須仰賴人工手動構建（如 One-Hot Hour、hr * workingday）	自動捕捉變數間的多階交互作用（Interaction Effects）
共線性應對	仰賴 Lasso / ElasticNet 懲罰或 VIF 剔除特徵	對多重共線性天然具備高度容忍性
運算與記憶體需求	矩陣運算，毫秒級推論，極端輕量	需儲存樹狀節點，計算複雜度隨樹深與樹數量增加
模型定位	**基準對照（Baseline）與因果/邊際效應分析**	**實務營運與競賽追求最高預測準確度之核心解法**

---

7. 報告研究摘要（**150–250** 字）

本研究針對華盛頓特區 Capital Bikeshare 系統之每小時單車租借需求進行預測與影響因子分析。研究以多元線性回歸為核心基準，探討氣溫、濕度、天候、工作日與尖峰時段對每小時租借量之邊際影響，並透過 Lasso、ElasticNet、Forward SFS 及 RFE 等方法評估特徵選取效益。實證顯示，溫度呈現顯著正向關聯，惡劣天氣與高濕度則明顯壓抑騎乘需求，且工作日與休閒日展現顯著相異的時段週期特徵。相較於隨機森林與梯度提升等能自主擬合非線性關係的主流機器學習模型，線性回歸具備高度解釋力與低運算成本優勢，適合作為物聯網邊緣節點之輕量化排程參考依據。

---

8. 資料來源與引用依據

1. **UCI Machine Learning Repository: Bike Sharing Dataset**
    - 論文依據：Fanaee-T, H., & Gama, J. (2014). *Event labeling combining ensemble detectors and background knowledge*. Progress in Artificial Intelligence, 2(2), 113–127.
    - 資料內容：美國華盛頓特區 Capital Bikeshare（2011–2012）連續兩年之 hour.csv（17,389 筆）與 day.csv（731 筆）。
2. **Kaggle Competition: Bike Sharing Demand**

- 網址：[suspicious link removed]
- 指標依據：官方評估標準 Root Mean Squared Logarithmic Error（RMSLE），採用 1–19 日為訓練集、20 日至月底為測試集之分割設計。

3. **Scikit-learn 官方文件: Linear Models & Feature Selection**
   - 模組依據：sklearn.linear_model.Lasso, sklearn.linear_model.ElasticNet, sklearn.feature_selection.SequentialFeatureSelector, sklearn.feature_selection.RFE。
4. **MDPI Sustainability (2024) 共享單車需求預測研究**
   - 論文依據：Torres, J., Jiménez-Meroño, E., & Soriguera, F. (2024). *Forecasting the Usage of Bike-Sharing Systems through Machine Learning Techniques to Foster Sustainable Urban Mobility*. Sustainability, 16(16), 6910. DOI: 10.3390/su16166910。
   - 結論依據：針對 Random Forest、Gradient Boosting 及類神經網路進行比對，證實 Random Forest 在預測精度相當的情況下具備更簡易穩定的超參數校準特性。

- **資料集來源與研究脈絡:**

一、資料集來源（Dataset Source）

本研究採用 UCI Machine Learning Repository 所提供的 Bike Sharing Dataset，並參考 Kaggle 平台上的 Bike Sharing Demand 預測競賽。

資料集記錄美國華盛頓特區 Capital Bikeshare 共享單車系統於 2011 年至 2012 年的租借情況，並結合天氣、季節、時間及工作日等資訊，可用於分析不同環境條件對租借需求的影響。

資料集基本資訊:

項目	內容
資料集名稱	Bike Sharing Dataset
資料來源	UCI Machine Learning Repository
資料檔案	hour.csv
資料筆數	17,379 筆
資料期間	2011–2012 年
預測目標	cnt（每小時租借總數）
任務類型	Regression（迴歸預測）
建模特徵	18 個（包含特徵工程）

資料集連結：

- UCI Bike Sharing Dataset（實際資料來源）
- Kaggle Bike Sharing Demand（相關競賽）

注意：UCI 的 hour.csv 與 Kaggle 競賽資料雖然有相近的研究背景，但欄位格式與資料切分方式不完全相同。本專案實際使用的是 UCI hour.csv，不能直接宣稱使用了 Kaggle 官方競賽的訓練與測試資料。

二、研究背景（Research Background）

近年來，共享單車成為都市短程交通的重要選擇之一，具有便利性及減少交通負擔等優點。然而，共享單車的租借需求容易受到時間、天氣與季節等因素影響，例如上下班尖峰時段可能出現大量租借需求，而不良天氣則可能減少使用量。

若業者無法掌握不同時段的需求變化，便可能發生部分站點缺車或車輛閒置等情況。因此，透過歷史租借資料建立預測模型，有助於提前了解需求變化，作為車輛調度與營運規劃的參考。

三、研究方法與選擇原因（Research Motivation）

共享單車需求預測屬於回歸問題，常見的方法包含 Multiple Linear Regression、Random Forest、Gradient Boosting 等。

其中，非線性機器學習方法可以學習較複雜的特徵關係，而多元線性回歸的優

點在於模型架構簡單、容易解釋，且能觀察不同變數與預測結果的關係。
因此，本研究選擇 Multiple Linear Regression 作為主要模型，並加入 Feature Selection 比較不同特徵組合對預測表現的影響。
此外，透過 MAE、RMSE、R^2 等指標評估模型，並使用 95% 預測區間呈現預測的不確定性，進一步了解線性模型在共享單車需求預測上的能力與限制。

四、研究目的（Research Objectives）

本研究主要希望達成以下目標：

1. 分析時間、溫度、濕度及工作日等因素與共享單車需求的關係。
2. 使用多元線性回歸預測每小時的共享單車租借數量。
3. 比較不同 Feature Selection 方法，找出較具預測價值的特徵。
4. 透過模型評估指標與預測區間，分析模型的準確性及限制。
5. 將分析成果整合為互動式網頁，方便觀察不同條件下的預測結果。

五、建議放在報告中的研究流程圖



- **主流與更優解法比較:**

一、常見預測方法

共享單車需求容易受到時間、天氣、季節及工作日等因素影響。除了本研究採用的多元線性回歸外，常見的預測方法還包含 Random Forest、XGBoost、LightGBM 和 LSTM。

模型	優點	缺點
Multiple Linear Regression	計算快速、容易解釋特徵影響	難以直接捕捉複雜非線性關係
Random Forest	能處理非線性及特徵交互作用	解釋性較低、模型較大
XGBoost	擅長處理表格資料，預測能力通常較強	需要調整超參數
LightGBM	訓練效率高，適合大量資料	需要調參以避免過度擬合
LSTM	能學習時間序列中的長短期相依關係	訓練較複雜，需要設計序列輸入

二、本研究與其他方法的比較

本研究使用 Multiple Linear Regression 作為主要模型，並透過 Lasso、RFE、Forward SFS 等方法進行特徵選取。

依照目前的實驗紀錄，模型在測試集取得：

- $R^2 = 0.5824$
- RMSE = 138.99 輛
- MAE = 100.92 輛

雖然多元線性回歸可以解釋不同特徵與租借數量的關係，但共享單車需求受到上下班尖峰、天氣變化及季節交互作用的影響，可能存在較複雜的非線性模式。

因此，Random Forest、XGBoost 或 LightGBM 等樹模型，可能更容易捕捉這些關係，具有改善預測能力的潛力。

不過，本研究沒有在相同測試集上實際訓練這些模型，因此不能直接宣稱它們的預測結果一定優於本研究。

三、網路研究文獻比較

我找到兩份可以實際引用的研究資料。

研究一：Forecasting the Usage of Bike-Sharing Systems through Machine Learning Techniques（2024）

這篇研究使用紐約市共享單車資料，比較 Random Forest、Gradient Boosting 與人工神經網路。研究結果指出，三種方法的預測準確度相近，但 Random Forest 的調參過程較簡單，因此具有實務應用優勢。

研究二：Using Machine Learning Methods to Predict Demand for Bike Sharing（2022）

這篇研究使用首爾共享單車資料，比較 Linear Regression、KNN、Random Forest 與 SVM，並考慮天氣以外的空氣污染、交通及社會經濟因素，說明共享單車預測可以從不同模型與更多資料特徵進行改善。